知

首发于
深海遨游

关注专栏

写文章

登录

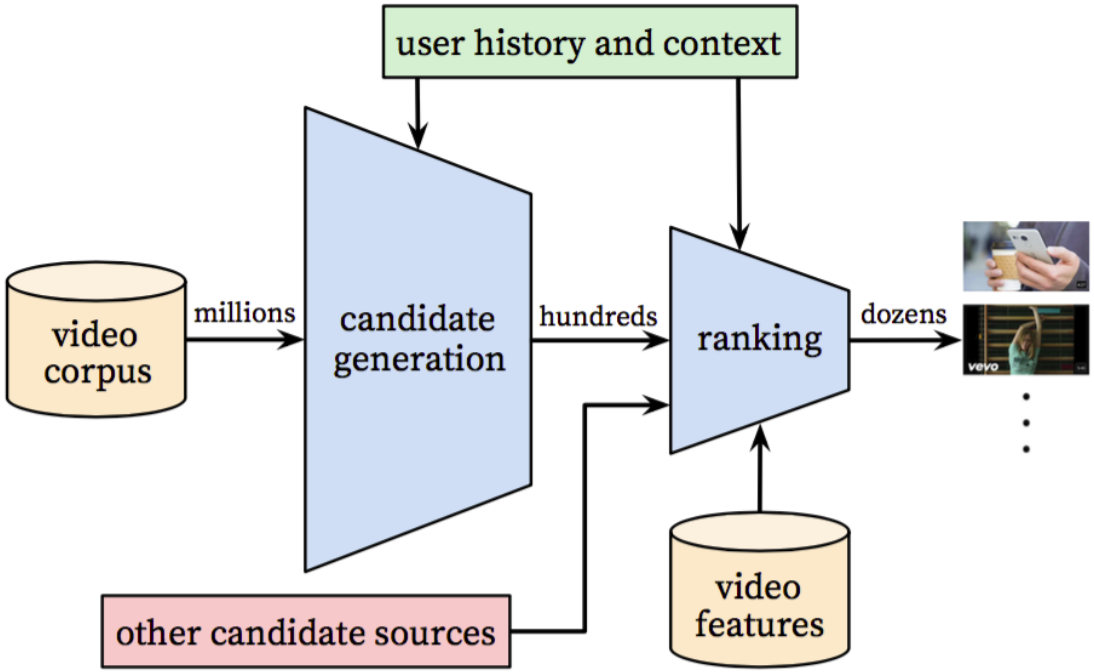

用深度学习（DNN）构建推荐系统 - Deep Neural Networks for YouTube Recommendations论文精读

清淞 · 5 个月前

这篇论文 Deep Neural Networks for YouTube Recommendations 是google的YouTube团队

在推荐系统上DNN方面的尝试，发表在16年9月的RecSys会议。虽然去年读过，一方面因为这篇paper的来源于youtube团队的工业实践，G家的东西，非常值得好好研究下；另一方面，目前正在公司推进的项目对该论文有参考（both method and insight），也正准备在team内部分享下，因此整理下论文精读笔记。（PS：为方便阅读，下文以第一人称代替作者）

虽然国内必须翻墙才能登录YouTube，但想必大家都知道这个网站。基本上算是世界范围内视频领域的最大的网站了，坐拥10亿量级的用户，网站内的视频推荐自然是一个非常重要的功能。本文就focus在**YouTube视频推荐的DNN算法，文中不但详细介绍了Youtube推荐算法和架构细节，还给了不少practical lessons and insights，很值得精读一番**。下图便是YouTube APP视频推荐的一个例子。

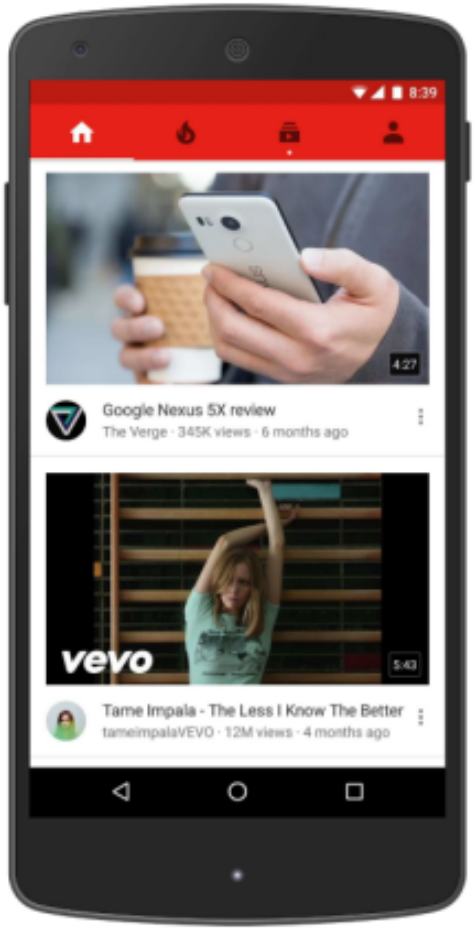

Figure 1: Recommendations displayed on YouTube mobile app home.

在推荐系统领域，特别是YouTube的所在视频推荐领域，主要面临三个挑战：

- **规模大**：用户和视频的数量都很大，只能适应小规模数据集的算法就不考虑了。
- **更新快**：youtube视频更新频率很高，每秒有小时级别的视频上传，需要在新发布视频和已有存量视频间进行balance。更新快（实时性）的另一方面的体现是用户实时行为切换

很快，模型需要很好的追踪用户的实时行为。

- **噪音**：噪音主要体现在用户的历史行为往往是稀疏的并且是不完整的，并且没有一个明确的ground truth的满意度signal，我们面对的都是noisy implicit feedback signals。噪音另一个方面就是视频本身很多数据都是非结构化的。这两点对算法的鲁棒性提出了很高的挑战。

之所以要在推荐系统中应用DNN解决问题，一个重要原因是google内部在机器学习问题上的通用solution的趋势正转移到Deep learning，系统实际部署在基于tensorflow的Google Brain上。

一、系统概览

在工业界工作的同学对下图的系统划分并不陌生。整个推荐系统分为candidate generation（淘宝称为Matching，后面用Matching代替）和Ranking两个阶段。Matching阶段通过i2i/u2i/u2u/user profile等方式“粗糙”的召回候选商品，Matching阶段视频的数量是百级别了；Ranking阶段对Matching后的视频采用更精细的特征计算user-item之间的排序分，作为最终输出推荐结果的依据。

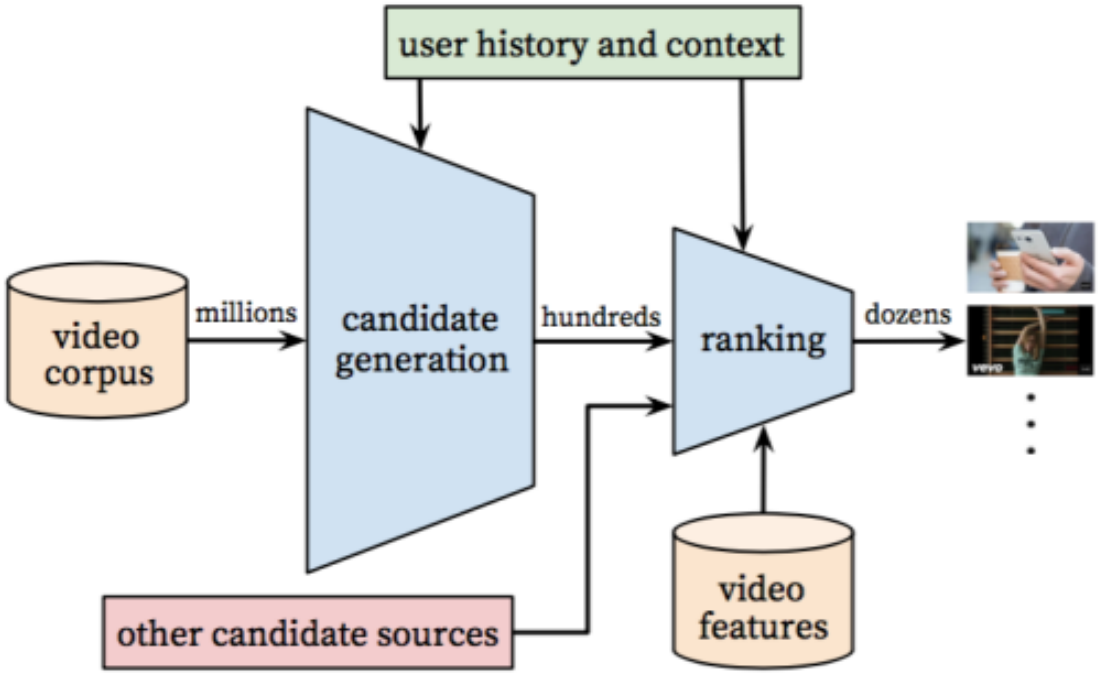

Figure 2: Recommendation system architecture demonstrating the "funnel" where candidate videos are retrieved and ranked before presenting only a few to the user.

之所以把推荐系统划分成Matching和Ranking两个阶段，主要是从性能方面考虑的。Matching阶段面临的是百万级视频，单个视频的性能开销必须很小；而Ranking阶段的算法则非常消耗资源，不可能对所有视频都算一遍，实际上即便资源充足也完全没有必要，因为往往来说通不过Matching粗选的视频，大部分在Ranking阶段排名也很低。接下来分别从Matching和Ranking阶段展开介绍。

二、Matching

2.1 问题建模

我们把推荐问题建模成一个“超大规模多分类”问题。即在时刻 t ，为用户 U （上下文信息 C ）在视频库 V 中精准的预测出视频 i 的类别（每个具体的视频视为一个类别， i 即为一个类别），用数学公式表达如下：

$$P(w_t = i|U, C) = \frac{e^{v_i u}}{\sum_{j \in V} e^{v_j u}}$$

很显然上式为一个softmax多分类器的形式。向量 $u \in R^N$ 是<user, context>信息的高纬“embedding”，而向量 $v_j \in R^N$ 则是视频 j 的embedding向量。所以DNN的目标就是在用户信息和上下文信息为输入条件下学习用户的embedding向量 u 。用公式表达DNN就是在拟合函数 $u = f_{DNN}(user_info, context_info)$ 。

而这种超大规模分类问题上，至少要有几百万个类别，实际训练采用的是Negative Sampe，类似于word2vec的Skip-Gram方法，类似我专栏的第一篇文章 DNN论文分享 - Item2vec: Neural Item Embedding for Collaborative Filtering 的item-embedding用的方法。

2.2 模型架构

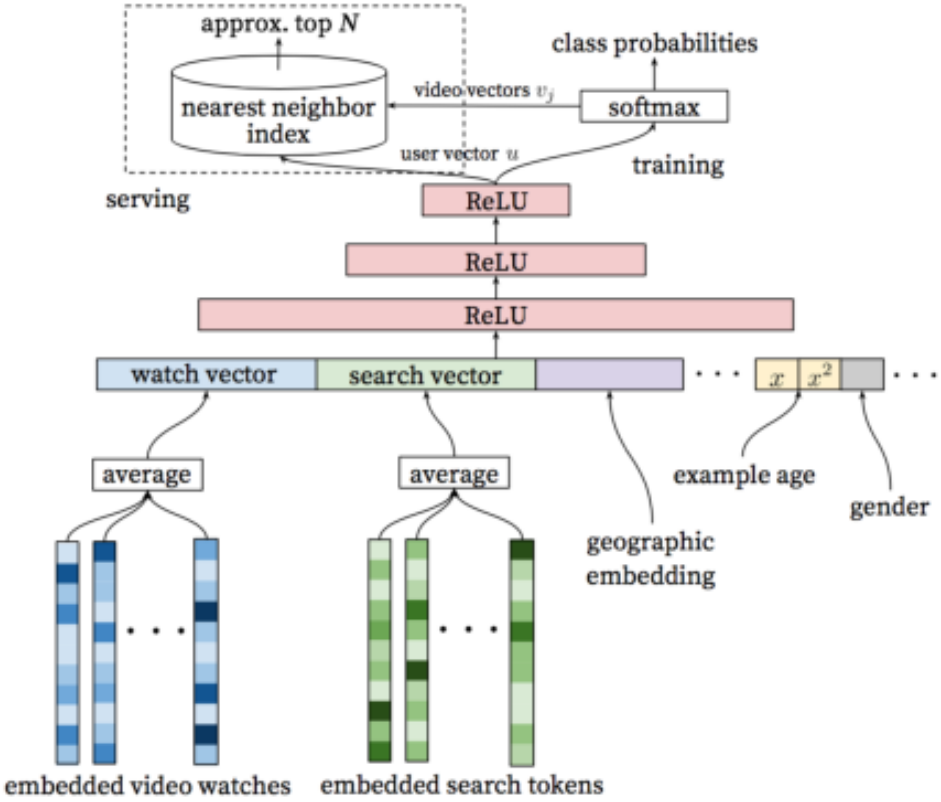

整个模型架构是包含三个隐层的DNN结构。输入是用户浏览历史、搜索历史、人口统计学信息和其余上下文信息concat成的输入向量；输出分线上和离线训练两个部分。

离线训练阶段输出层为softmax层，输出2.1公式表达的概率。而线上则直接利用user向量查询相关商品，最重要问题是在性能。我们利用类似局部敏感哈希（Locality Sensitive Hashing，不展开介绍了，感兴趣的同学可以读读这篇论文 An Investigation of Practical Approximate Nearest Neighbor Algorithms ）的算法为用户提供最相关的N个视频。

2.3 主要特征

类似于word2vec的做法，每个视频都会被embedding到固定维度的向量中。用户的**观看视频历史**则是通过变长的视频序列表达，最终通过**加权平均（可根据重要性和时间进行加权）**得到固定维度的watch vector作为DNN的输入。

除历史观看视频外的其他signal：

其实熟悉Skip-Gram方法的同学很容易看出来，2.1把推荐问题定义为“超大规模多分类”问题的数学公式和word2vec的Skip-Gram方法的公式基本相同，所不同的是user_vec是通过DNN学习到的，而**引入DNN的好处则是任意的连续特征和离散特征可以很容易添加到模型当中**。同样的，推荐系统常用的矩阵分解方法虽然也能得到user_vec和item_vec，但同样是不能嵌入更多feature。

主要特征：

- **历史搜索query**：把历史搜索的query分词后的token的embedding向量进行加权平均，能够反映用户的整体搜索历史状态
- **人口统计学信息**：性别、年龄、地域等
- **其他上下文信息**：设备、登录状态等

“Example Age”（视频上传时间）特征

视频网络的时效性是很重要的，每秒YouTube上都有大量新视频被上传，而对用户来讲，哪怕牺牲相关性代价，用户还是更倾向于更新的视频。当然我们不会单纯的因为一个视频新就直接推荐给用户。

因为机器学习系统在训练阶段都是利用过去的行为预估未来，因此通常对过去的行为有个隐式的bias。视频网站视频的分布是高度非静态（non-stationary）的，但我们的推荐系统产生的视

频集合在视频的分布，基本上反映的是训练所取时间段的平均的观看喜好的视频。因此我们我们把样本的 “age” 作为一个feature加入模型训练中。从下图可以很清楚的看出，加入“example age” feature后和经验分布更为match。

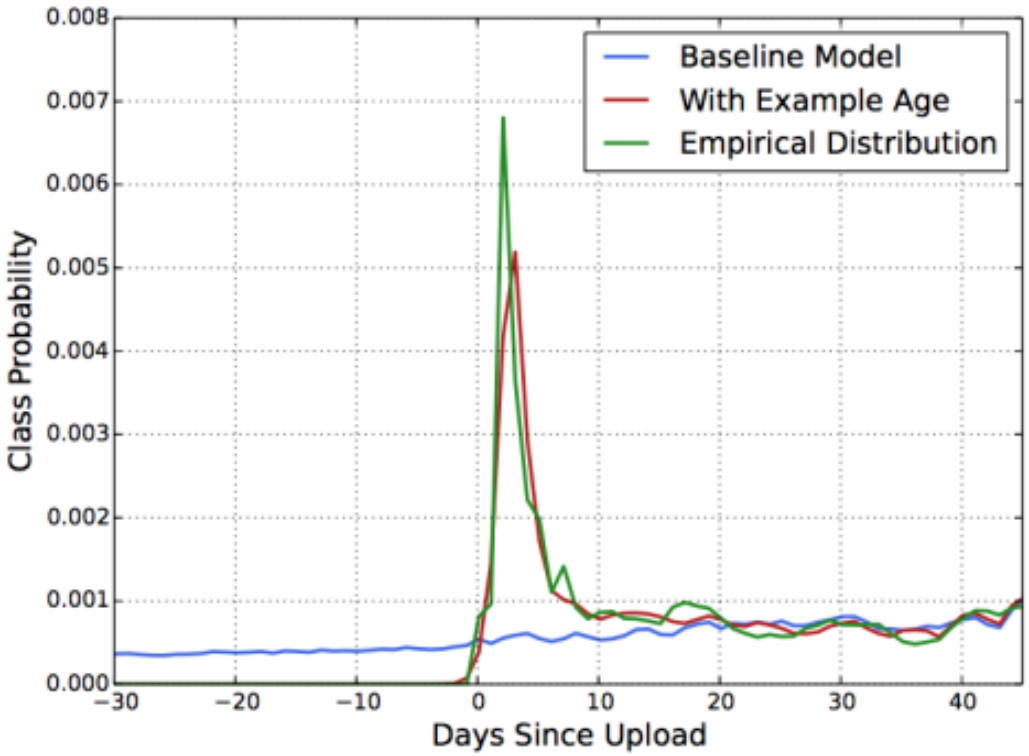

2.4 label and context selection

在有监督学习问题中，最重要的选择是label了，因为label决定了你做什么，决定了你的上限，而feature和model都是在逼近label。我们的几个设计如下：

- **使用更广的数据源**：不仅仅使用推荐场景的数据进行训练，其他场景比如搜索等的数据也要用到，这样也能为推荐场景提供一些explore。

- **为每个用户生成固定数量训练样本**：我们在实际中发现的一个practical lessons，如果为每个用户固定样本数量上限，平等的对待每个用户，避免loss被少数active用户domanate，能明显提升线上效果。
- **抛弃序列信息**：我们在实现时尝试的是去掉序列信息，对过去观看视频/历史搜索query的embedding向量进行加权平均。这点其实违反直觉，可能原因是模型对负反馈没有很好的建模。
- **不对称的共同浏览（asymmetric co-watch）问题**：所谓asymmetric co-watch值的是用户在浏览视频时候，往往都是序列式的，开始看一些比较流行的，逐渐找到细分的视频。下图所示图(a)是hled-out方式，利用**上下文信息**预估中间的一个视频；图(b)是predicting next watch的方式，则是利用**上文信息**，预估下一次浏览的视频。我们发现图(b)的方式在线上A/B test中表现更佳。*而实际上，传统的协同过滤类的算法，都是隐含的采用图(a)的held-out方式，忽略了不对称的浏览模式。*

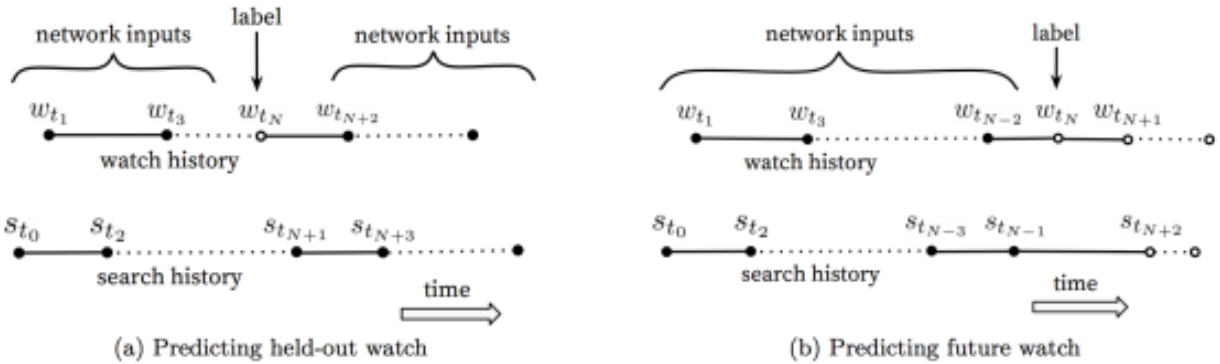

2.4 不同网络深度和特征的实验

简单介绍下我们的网络构建过程，采用的经典的“tower”模式搭建网络，基本同2.2所示的网络架构，所有的视频和search token都embedded到256维的向量中，开始input层直接全连接到256维的softmax层，依次增加网络深度（+512-->+1024-->+2048--> ...）。

- Depth 0: A linear layer simply transforms the concatenation layer to match the softmax dimension of 256
- Depth 1: 256 ReLU
- Depth 2: 512 ReLU $\rightarrow$ 256 ReLU
- Depth 3: 1024 ReLU $\rightarrow$ 512 ReLU $\rightarrow$ 256 ReLU
- Depth 4: 2048 ReLU $\rightarrow$ 1024 ReLU $\rightarrow$ 512 ReLU $\rightarrow$ 256 ReLU

下图反映了不同网络深度（横坐标）下不同特征组合情况下的holdout-MAP（纵坐标）。可以很明显看出，增加了观看历史之外的特征很明显的提升了预测得准确率；从网络深度看，随着网络深度加大，预测准确率在提升，但继续增加第四层网络已经收益不大了。

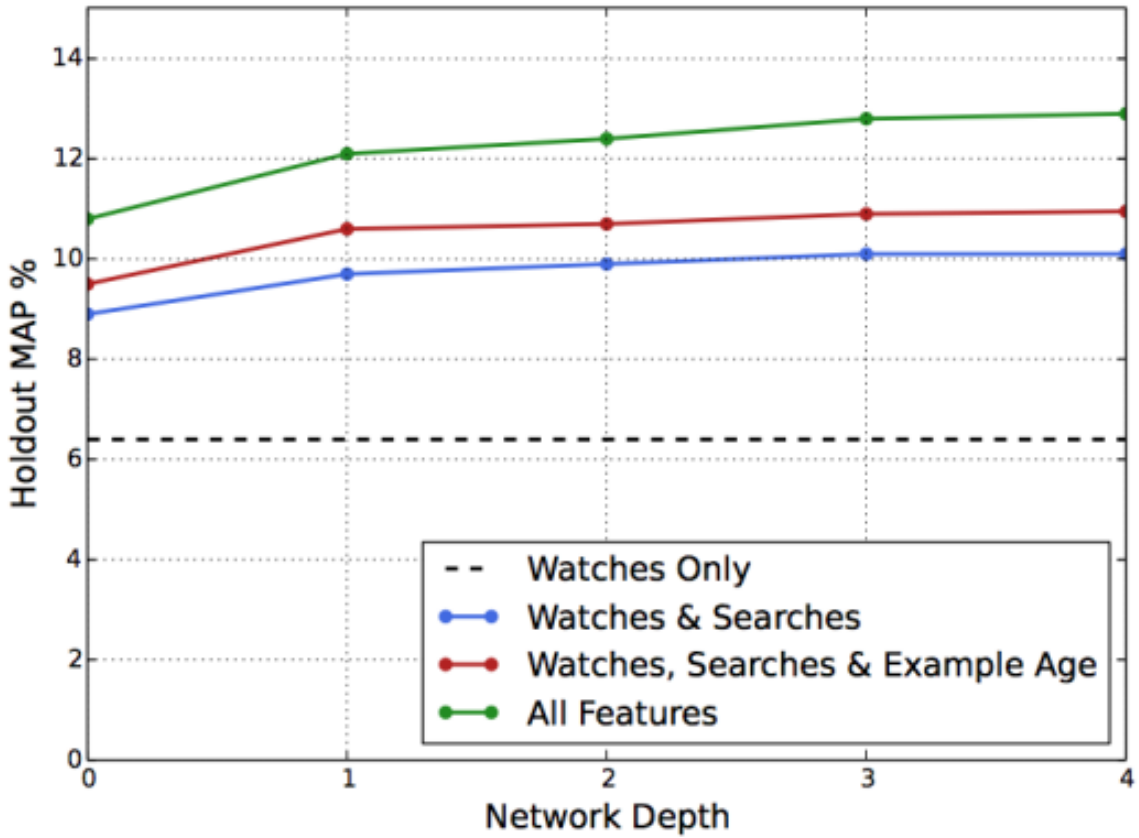

Figure 6: Features beyond video embeddings improve holdout Mean Average Precision (MAP) and layers of depth add expressiveness so that the model can effectively use these additional features by modeling their interaction.

三、Ranking

Ranking阶段的最重要任务就是精准的预估用户对视频的喜好程度。不同于Matching阶段面临的是百万级的候选视频集，Ranking阶段面对的只是百级别的商品集，因此我们可以*使用更多更精细的feature*来刻画视频（item）以及用户与视频（user-item）的关系。比如用户可能很喜欢某个视频，但如果list页的用的“缩略图”选择不当，用户也许不会点击，等等。

此外，Matching阶段的来源往往很多，没法直接比较。Ranking阶段另一个关键的作用是能够把不同来源的数据进行有效的ensemble。

在目标的设定方面，单纯CTR指标是有迷惑性的，有些靠关键词吸引用户高点击的视频未必能够被播放。因此设定的目标基本与期望的观看时长相关，具体的目标调整则根据线上的A/B进行调整。

3.1 模型架构

Ranking阶段的模型和Matching基本相似，不同的是training最后一层是一个weighted LR层，而serving阶段激励函数用的是 e^x ，具体在3.3阐述。

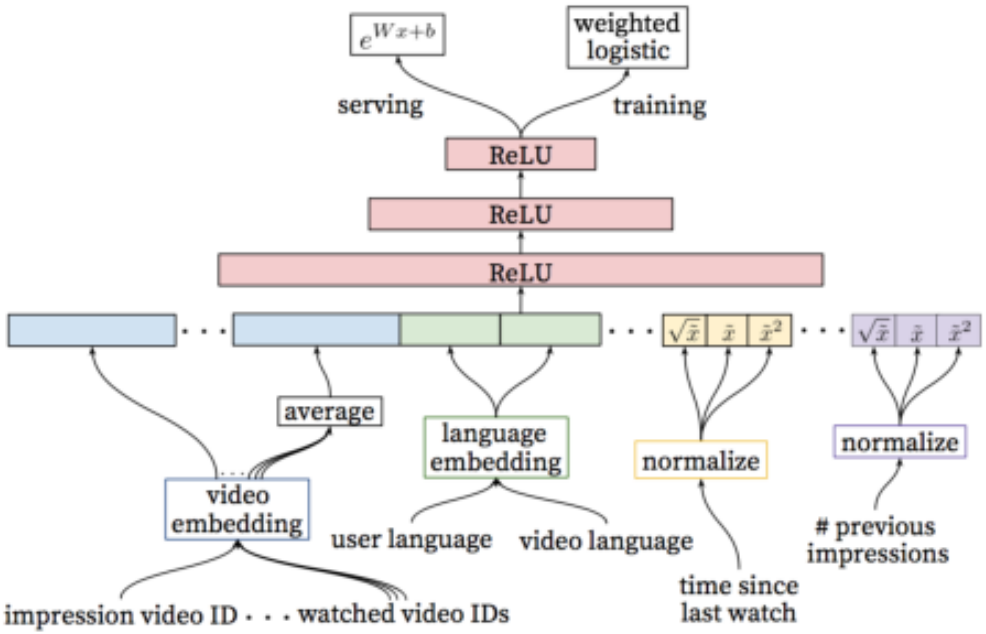

3.2 特征表达

a). Feature Engineering：

尽管深度学习在图像、语音和NLP等场景都能实现end-to-end的训练，没有了人工特征工程工作。然而在搜索和推荐场景，我们的很难吧原始数据直接作为FNN的输入，*特征工程仍然很重要*。而特征工程中最难的是如何建模用户时序行为（***temporal sequence of user actions***），并且关联这些行为和要rank的item。

我们发现**最重要的Signal是描述用户与商品本身或相似商品之间交互的Signal**，这与Facebook在14年提出LR+GBDT模型的paper（Practical Lessons from Predicting Clicks on Ads at Facebook ）中得到的结论是一致的。比如我们要度量用户对视频的喜欢，可以考虑用户与视频所在频道间的关系：

- **数量特征**：浏览该频道的次数？
- **时间特征**：比如最近一次浏览该频道距离现在的时间？

这两个连续特征的最大好处是具备非常强的泛化能力。另外除了这两个偏正向的特征，用户对于视频所在频道的一些PV但不点击的行为，即**负反馈Signal同样非常重要**。

另外，我们还发现，把Matching阶段的信息传播到Ranking阶段同样能很好的提升效果，比如推荐来源和所在来源的分数。

b). Embedding Categorical Features

NN更适合处理连续特征，因此稀疏的特别是高基数空间的离散特征需要embedding到稠密的向量中。每个维度（比如query/user_id）都有独立的embedding空间，一般来说空间的维度基本与log(去重后值得数量)相当。实际并非为所有的id进行embedding，比如视频id，只需要按照点击排序，选择top N视频进行embedding，其余置为0向量。而对于像“过去点击的视频”这种multivalent特征，与Matching阶段的处理相同，进行加权平均即可。

另外一个值得注意的是，同维度不同feature采用的相同ID的embedding是共享的（比如“过去浏览的视频id” “seed视频id”），这样可以大大加速训练，但显然输入层仍要分别填充。

c). Normalizing Continuous Features

众所周知，NN对输入特征的尺度和分布都是非常敏感的，实际上基本上除了Tree-Based的模型（比如GBDT/RF），机器学习的大多算法都如此。我们发现归一化方法对收敛很关键，推荐一种排序分位归一到[0,1]区间的方法，即 $\tilde{x} = \int_{-\infty}^{x} df$ ，累计分位点。

除此之外，我们还把归一化后的 $\bar{x}$ 的根号 $\sqrt{x}$ 和平方 x^2 作为网络输入，以期能使网络能够更容易得到特征的次线性（sub-linear）和（super-linear）超线性函数。

3.3 建模期望观看时长

我们的目标是预测**期望观看时长**。有点击的为正样本，有PV无点击的为负样本，正样本需要根据观看时长进行加权。因此，我们训练阶段网络最后一层用的是 weighted logistic regression。

正样本的权重为观看时长 T_i ，负样本权重为1。这样的话，LR学到的odds为：

其中 N 是总的样本数量，k 是正样本数量，T_i 是第 i 正样本的观看时长。一般来说，k相对N比较小，因此上式的odds可以转换成 $E[T]/(1+P)$ ，其中 P 是点击率，点击率一般很小，这样odds接近于 $E[T]$ ，即期望观看时长。因此在线上serving的inference阶段，我们采用 e^x 作为激励函数，就是近似的估计期望的观看时长。

3.4 不同隐层的实验

下图的table1是离线利用hold-out一天数据在不同NN网络结构下的结果。如果用户对模型预估高分的反而没有观看，我们认为是预测错误的观看时长。weighted, per-user loss就是预测错误观看时长占总观看时长的比例。

我们对网络结构中隐层的宽度和深度方面都做了测试，从下图结果看增加隐层网络宽度和深度都能提升模型效果。而对于1024-->512-->256这个网络，测试的不包含归一化后根号和方式的版本，loss增加了0.2%。而如果把weighted LR替换成LR，效果下降达到4.1%。

Hidden layers	weighted, per-user loss
None	41.6%
256 ReLU	36.9%
512 ReLU	36.7%
1024 ReLU	35.8%
512 ReLU → 256 ReLU	35.2%
1024 ReLU → 512 ReLU	34.7%
1024 ReLU → 512 ReLU → 256 ReLU	34.6%

Table 1: Effects of wider and deeper hidden ReLU layers on watch time-weighted pairwise loss computed on next-day holdout data.

四、总结

虽然早就读过这篇文章，但是精读之后，发现新收获仍然不少。对于普通的学术论文，重要的是提供一些新的点子，而对于类似google这种工业界发布的paper，特别是带有practical lessons的paper，很值得精读。另外一点就是，论文中提到的一些insight和我们在淘宝商品搜索排序场景的一些insight非常的契合，读来别有感觉。

最后安利下我们team的招聘，对淘宝搜索排序感兴趣的同学欢迎邮件我 qingsong.huaqs@taobao.com，来淘宝，一起成长！

「真诚赞赏，手留余香」

赞赏

1 人赞赏

深度学习（Deep Learning） 推荐系统

神经网络

181 收藏 分享 举报

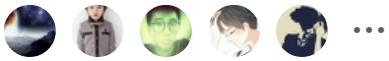

文章被以下专栏收录

深海遨游

一起在深度学习的“海洋”里自在遨游吧！😆

进入专栏

25 条评论

写下你的评论...

哈哈我最近也看了这篇，毕设就是深度学习做推荐系统。

5 个月前 1 赞

cherrysec

很有收货，主要收获是利用机器学习来实现视频分类，结合模型和特征实现推荐效果，我认为增加隐层还是为了更好地描述特征吧，很有很多东西值得学习！谢谢分享

5 个月前 1 赞

龚禹pangolulu

其实这篇文章无论是matching阶段还是ranking阶段都是用的pointwise-ltr的方法，不知道matching阶段用pairwise-ltr的方法效果怎么样？

5 个月前

头条君

感谢分享！已推荐到《开发者头条》：

用 DNN 构建推荐系统：Deep Neural Networks for YouTube Recommendations 论文精读
欢迎点赞支持！ 欢迎订阅《数据淘金》

热门分享 - 数据淘金

5 个月前

GW

楼主有实现论文吗？

4 个月前 1 赞

GW

建模期望观看时间这里，看不是很懂呢。fit数据进DNN时，是把[（单个视频特征，用户特征）-> 视频观看时长] 进去吗？但这样一个视频，weithted LR就不知道怎么跑起来了

4 个月前

Godzilla

很多insights都有同感，我15年实践过一个类似的系统，用Embedding 那时候还没什么人想到这个点子 现在似乎已经是state of the art了

4 个月前

龚禹pangolulu 回复 GW 查看对话

其实也是一个二分类问题，一个sample的特征相当于(用户，单个视频)pair的encode，只不过每一个sample都用观看时长加权，除了负样本权为1。

4 个月前

GW 回复 龚禹pangolulu 查看对话

对正样本，网络输入(用户，单个视频)，学习用户观看该视频的时长；负样本，对(用户，单个视频)，网络的输出就是1，这样？
但这样理解的话，就不是二分类，网络的输出是多分类啊，分类是各种时间的长度。望指教

4 个月前

龚禹pangolulu 回复 GW 查看对话

是在损失函数中加权，损失函数的形式还是logistic regression。

4 个月前

1 2 3 下一页

推荐阅读

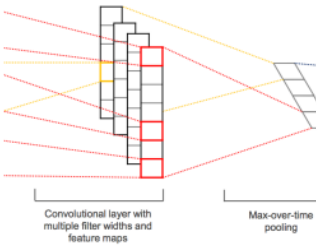

用深度学习（CNN RNN Attention）解决大规模文本分类问题 - 综述和实践

近来在同时做一个应用深度学习解决淘宝商品的类目预测问题的项目，恰好硕士毕业时论文题目便... 查看全文 >

清淞 · 3 个月前 · 发表于 深海遨游

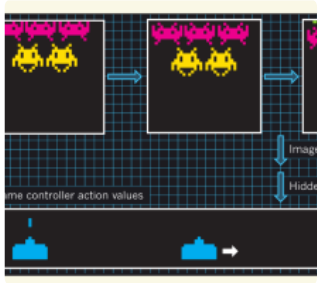

深度强化学习（Deep Reinforcement Learning）入门：RL base & DQN-DDPG-A3C introduction

过去的一段时间在深度强化学习领域投入了不少精力，工作中也在应用DRL解决业务问题。子曰：... 查看全文 >

清淞 · 5 个月前 · 发表于 深海遨游

致命的食物

不少对海洋生物捕食、斗争充满兴趣的朋友们喜欢对海里极具特色的掠食性动物的战斗力做个排名… 查看全文 ›

喵鱼酱 · 1 个月前 · 编辑精选 · 发表于 海错生灵

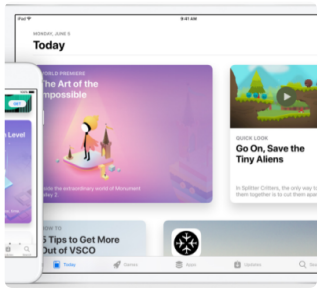

治大国如烹小鲜，苹果WWDC 2017之后App Store流量怎么玩？！

6月6日，苹果公司发布了新版操作系统iOS11，而新版的App Store是自苹果2009年开通App Store… 查看全文 ›

以史为贱 · 1 个月前 · 编辑精选 · 发表于 APP反作弊与互联网杂谈