AlgorithmDog
freedom

强化学习系列之二:模型相关的强化学习

发表于2016年4月10日由lili

文章目录 [隐藏]

上一章我们介绍了强化学习的基本假设——马尔科夫决策过程 (Markov Decision Process)。本文将介绍模型相关的强化学习算法。

有的时候，我们完全知道问题背后的马尔科夫决策过程；有的时候，我们不知道问题背后的马尔科夫决策过程 (主要指我们不知奖励函数 $R_{s,a}$ 和转移概率 $P_{s,a}^{s'}$ 的全貌)。根据马尔科夫决策过程是否可知，强化学习可以分为两类: 模型相关 (Model-based) 和模型无关 (Model-free)。模型相关是我们知道整个马尔科夫决策过程。模型无关则是我们不知道马尔科夫决策过程，需要系统进行探索。今天我们先介绍比较简单的模型相关强化学习。

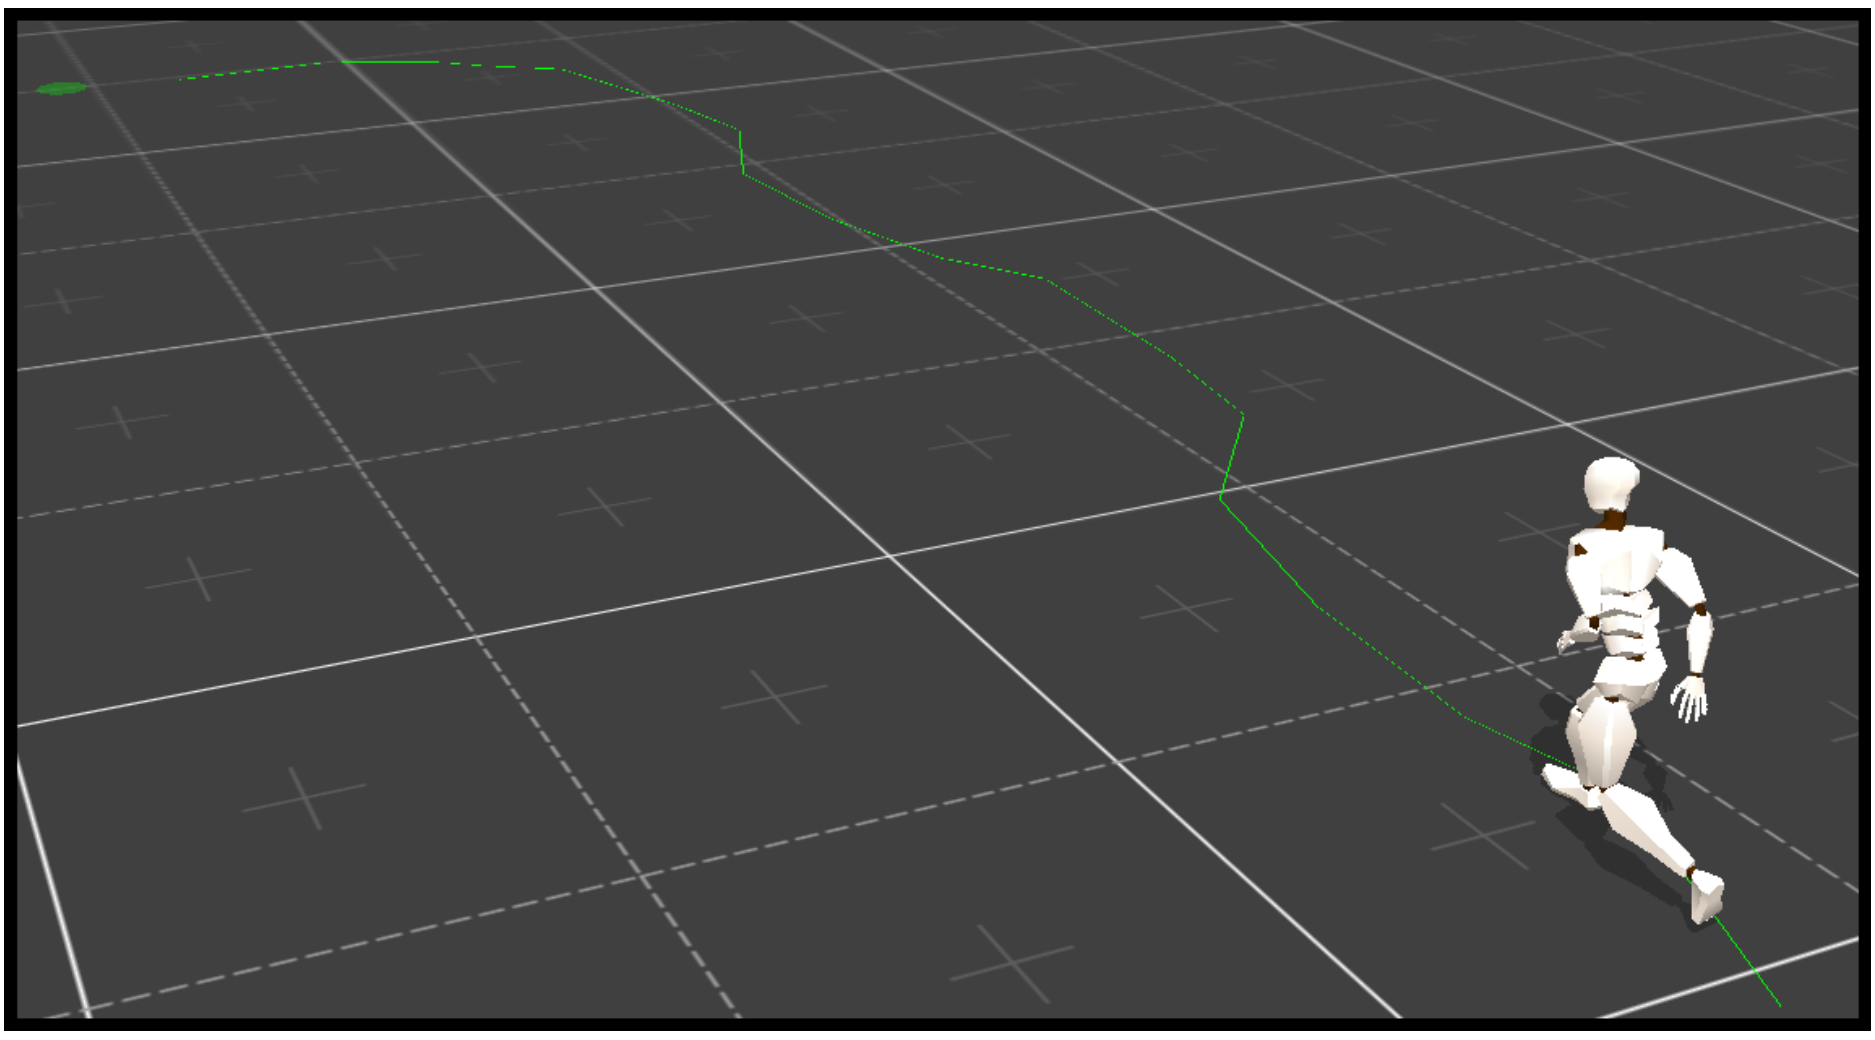

本文还是以机器人寻找金币为例子。如下图所示，一个机器人出发寻找金币。找到金币则获得奖励 1，碰到海盗则损失 1。找到金币或者碰到海盗则机器人停止。图中不同位置为状态，因此状态集合 S = {1,...,5}。机器人采取的动作是向东南西北方向走，因此A={'n','e','s','w'}。转移概率方面，当机器人碰到墙壁，则会停在原来的位置；当机器人找到金币时获得奖励 1，当碰到海盗则损失 1, 其他情况不奖励也不惩罚。因此除了 $R_{1,s}=-1$, $R_{3,s}=1$，$R_{5,s}=-1$ 之外，其他情况$R_{*,*}=0$。γ衰减因子等于 0.8。

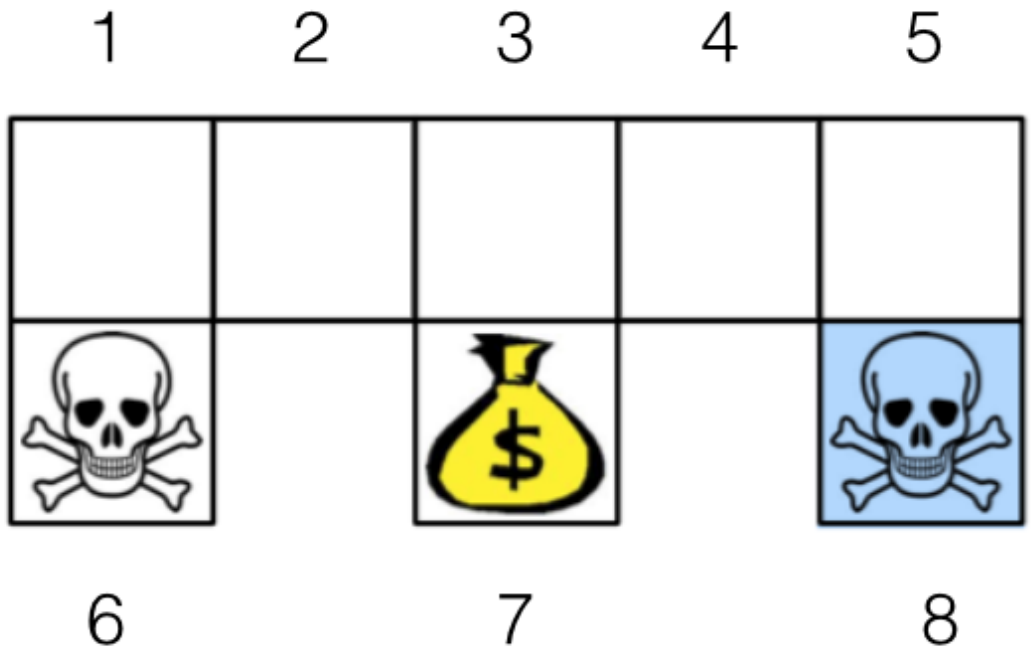

马尔科夫决策过程的具体实现，可以看这里。为了实现今天要介绍的算法，我们先定义表示策略和价值的数据结构。

```
class Policy_Value:
    def __init__(self, grid_mdp):
        //self.v[state] 等于状态 state 的价值。
        self.v  = [ 0.0 for i in xrange(len(grid_mdp.states) + 1)]

        //self.pi[state] 等于策略在状态 state 下采取的动作
        self.pi = dict()
        for state in grid_mdp.states:
            if state in grid_mdp.terminal_states: continue
            self.pi[state] = grid_mdp.actions[ 0 ]
```

1. 策略迭代

模型相关的强化学习算法主要有：策略迭代 (Policy Iteration) 和价值迭代 (Value Iteration)。策略迭代的主要思想是这样的。先随机初始化一个策略 π_0，计算这个策略下每个状态的价值 $\boldsymbol{v}_0$；根据这些状态价值得到新策略 π_1；计算新策略下每个状态的价值 $\boldsymbol{v}_1$ ... 直到收敛。计算一个策略下每个状态的价值，被称为策略评估 (Policy Evaluation)；根据状态价值得到新策略，被称为策略改进 (Policy Improvement)。

1.1 策略评估

策略评估利用了贝尔曼等式。根据贝尔曼等式，一个状态的价值和它后续状态的价值有关。因此我们用后续状态价值 $v(s')$ 去更新当前状态的价值 $v(s)$。策略评估遍历所有状态，按照下面公式更新其价值。

$$v(s) = \sum_{a \in A} \pi(s,a)(R_{s,a} + \gamma \sum_{s' \in S} T_{s,a}^{s'} v_t(s'))$$

由于状态之间是可以相互转移的，比如 s' 可以是 s 的后续状态，但反过来 s 也可以是 s' 后续状态。如果只遍历并更新一遍状态价值，状态价值并不是当前策略的价值。为此我们多次遍历并更新状态价值。策略评估的代码 (代码在这个链接下的 policy_iteration.py 中)。

```
// grid_mdp 是机器人找金币问题的马尔科夫决策过程
def policy_evaluate(self, grid_mdp):
        for i in xrange(1000):

            delta = 0.0
            for state in grid_mdp.states:
                if state in grid_mdp.terminal_states: continue
```

```
        // 当前策略输出动作
        action        = self.pi[state]
        // t 表示是否到了终止状态
        // s 表示状态 state 下执行动作 action 后的状态
        // r 表示奖励
        t, s, r       = grid_mdp.transform(state, action)
        //更新状态价值
        new_v         = r + grid_mdp.gamma * self.v[s]
        delta        += abs(self.v[state] - new_v)
        self.v[state] = new_v

    if delta < 1e-6:
        break;
```

1.2 策略改进

根据状态价值得到新策略，被称为策略改进。对于一个状态s，让策略选择一个动作a，使得当前状态的价值 $R_{s,a}+\gamma\sum_{s'\in S}T_{s,a}^{s'}v(s')$ 最大，即

$$\pi_{i+1}(s,a)=\begin{cases}1 & a=argmax_a R_{s,a}+\gamma\sum_{s'\in S}T_{s,a}^{s'}v(s') \\ 0 & a\neq argmax_a R_{s,a}+\gamma\sum_{s'\in S}T_{s,a}^{s'}v(s')\end{cases}$$

可以向你保证，这样得到的新策略一定是优于旧策略的，即$v_{\pi_{i+1}}(s)\geq v_{\pi_i}(s),\forall s$ (上一篇文章最后一节介绍的策略偏序关系)。具体证明就不详细列出了，说下大致思路：我们用策略评估计算新策略的状态价值；第一个要更新的状态是 s1，因为新策略选择价值最大的动作，因此新策略使得 v(s1) 上升；如果之前的更新都是使得价值上升，那么更新当前状态 sk 时，新策略还是使得价值上升；即使一个状态被多次更新，价值都是上升的。这样新策略优于旧策略。策略改进的代码如下 (代码在这个链接下的 policy_iteration.py 中)

```
def policy_improve(self, grid_mdp):

        for state in grid_mdp.states:
            if state in grid_mdp.terminal_states: continue

            a1      = grid_mdp.actions[0]
            t, s, r = grid_mdp.transform( state, a1 )
            v1      = r + grid_mdp.gamma * self.v[s]

            //找到当前状态的价值最大的动作 a1
            for action in grid_mdp.actions:
                t, s, r = grid_mdp.transform( state, action )
                if v1 < r + grid_mdp.gamma * self.v[s]:
                    a1 = action
                    v1 = r + grid_mdp.gamma * self.v[s]
        //更新策略
        self.pi[state] = a1
```

策略迭代交替执行策略评估和策略改进直到收敛，从而得到最优策略了。下图是策略迭代在机器人找金币问题中找到的最优解。

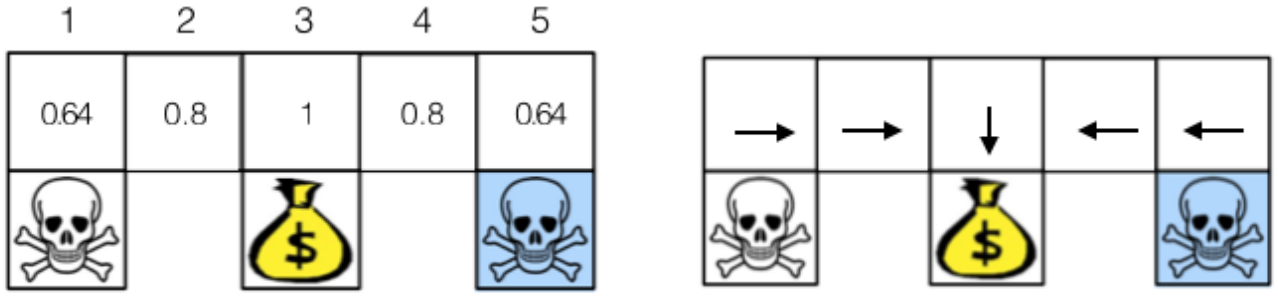

2. 价值迭代

看完策略迭代，我们发现策略迭代计算起来挺麻烦的，代码实现起来也麻烦。我们能不能把策略评估和策略改进结合得更紧密一些。一个状态下选择动作一旦确定，立刻按照这个动作计算当前状态的价值。这个做法其实就是价值迭代。价值迭代的代码如下所示 (代码在这个链接下的 value_iteration.py 中)。

```
def value_iteration(self, grid_mdp):
        for i in xrange(1000):

            delta = 0.0;
            for state in grid_mdp.states:

                    if state in grid_mdp.terminal_states: continue

                    a1      = grid_mdp.actions[0]
                    t, s, r = grid_mdp.transform( state, a1 )
                    v1      = r + grid_mdp.gamma * self.v[s]

                    for action in grid_mdp.actions:
                        t, s, r = grid_mdp.transform( state, action )
                        if v1 < r + grid_mdp.gamma * self.v[s]:
                            a1 = action
                            v1 = r + grid_mdp.gamma * self.v[s]

                delta          += abs(v1 - self.v[state])
                self.pi[state] = a1
                self.v[state]  = v1;

    if delta <  1e-6:
        break;
```

价值迭代一直执行直到收敛，从而获得最优策略。下图是价值迭代在机器人找金币问题中找到的最优解，和策略迭代找到的是一样的。

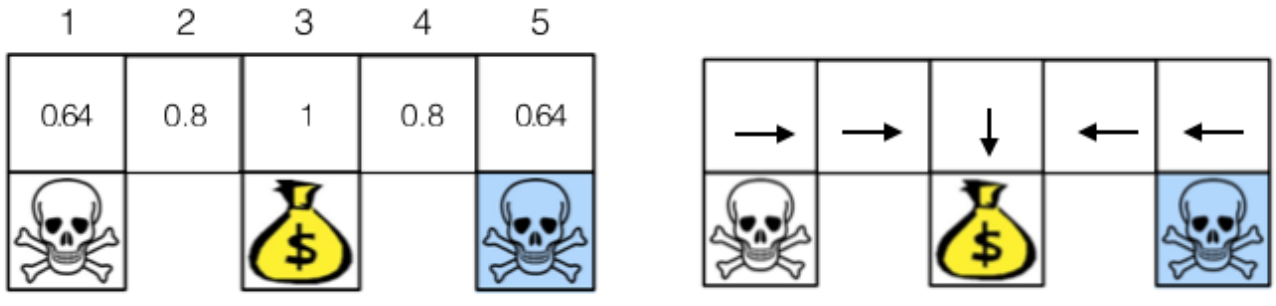

3. 总结性结尾（好魔性的标题）

本文介绍了模型相关的强化学习。模型相关的强化学习是指马尔科夫决策过程可知情况下的强化学习，其中策略迭代和价值迭代是主要的两种算法。本文代码可以在 Github 上找到，欢迎有兴趣的同学帮我挑挑毛病。强化学习系列的下一篇文章将介绍模型无关的强化学习，将涉及到 TD 、SARSA 和 Q-Learning 等著名算法。

文章结尾欢迎关注我的公众号 AlgorithmDog，每周日的更新就会有提醒哦~

weixin_saomiao

强化学习系列系列文章

- 强化学习系列之一:马尔科夫决策过程
- 强化学习系列之二:模型相关的强化学习
- 强化学习系列之三:模型无关的策略评价

- 强化学习系列之四:模型无关的策略学习
- 强化学习系列之五:价值函数近似
- 强化学习系列之六:策略梯度
- 强化学习系列之九:Deep Q Network (DQN)

此条目发表在强化学习, 算法荟萃分类目录，贴了强化学习标签。将固定链接加入收藏夹。

《强化学习系列之二:模型相关的强化学习》有 14 条评论

杨宇轩 说:
2016年4月12日下午1:34

期待下一篇，有示例和实际代码更容易理解了。谢谢博主分享

回复

jeff 说:
2016年4月26日下午4:43

楼主，你好，我想问一下你示例代码是自己写的吗？还是说有相关的资料。想知道你学习RL的资料～[挤眼]求推荐～

回复

上微博的猫V 说:
2016年4月26日下午5:17

代码是自己写的哈。学习资料是 David Silver 的课程，地址http://www0.cs.ucl.ac.uk/staff/d.silver/web/Teaching.html

回复

jeff 说:
2016年4月29日下午4:33

谢谢啦～

回复

学名马铃薯 说:
2016年5月5日上午11:29

我看价值迭代处的循环相反的传值需要再次计算，可不可以用马尔可夫随机场去处理迭代

回复

上微博的猫V 说:
2016年5月5日上午11:44

我不是很了解马尔可夫随机场哈。模型相关的强化学习用于讲解概念，实际用处倒是不大，所以也没有必要优化太多～

回复

敏 说:
2016年5月16日下午2:54

似乎没有体现转移概率?

回复

上微博的猫V*说:*
2016年5月16日下午4:04

找金币的例子中，转移概率确实不突出。你可以理解为T(1,'s',6) = 1, T(1,'s',除了6状态) = 0。

回复

闻风丧当 *说:*
2016年6月11日下午9:59

博主你好，感谢你的教程！在你的例子中，关于转移概率可以这样理解么？就是一旦动作决定了，转移函数的结果就是一个确定值，而不是一个分布。

回复

上微博的猫V*说:*
2016年6月13日下午7:33

恩恩，是的。你可以理解为p(1,'e',2) = 1,p(1,'e',3) = 0等等。

回复

庞小文 *说:*
2016年7月8日下午5:00

博主你好呀，所以我还有个问题，就是既然转移函数是确定的，那policy_evaluate这个函数里迭代1000次在这个程序里不是必须的？谢谢博主～～

回复

Wolfgang*说:*
2016年7月9日下午3:37

这里是必须的吧，因为计算Ut要达到收敛才行。

回复

Wolfgang*说:*
2016年7月9日下午3:39

博主你好，为什么improve function 里的 a1 = grid_mdp.actions[0] 每次都要是actions[0】呢，而不是当前pi下在该状态的action，也就是 self.pi[state] .

回复

韦峰 *说:*
2016年9月18日下午5:15

a1 = grid_mdp.actions[0] t, s, r = grid_mdp.transform(state, a1) v1 = r + grid_mdp.gamma * self.v 这个是不是和他下面的for action in grid_mdp.actions: t, s, r = grid_mdp.transform(state, action) if v1 < r + grid_mdp.gamma * self.v : a1 = action v1 = r + grid_mdp.gamma * self.v 重复了?

回复

AlgorithmDog
自豪地采用WordPress。