fly_time2012的专栏

bandit算法原理及Python实现

2017-04-17 15:26 258人阅读 评论(0)

分类： 推荐算法（30）

目录(?) [+]

Bandit算法是在线学习的一种，一切通过数据收集而得到的概率预估任务，都能通过Bandit系列算法来进行在线优化。这里的“在线”，指的不是互联网意义上的线上，而是只算法模型参数根据观察数据不断演变。

以多臂老虎机问题为例，首先我们假设每个臂是否产生收益，其背后有一个概率分布，产生收益的概率为p

我们不断地试验，去估计出一个置信度较高的概率p的概率分布就能近似解决这个问题了。

怎么能估计概率p的概率分布呢？ 答案是假设概率p的概率分布符合beta(wins, lose)分布，它有两个参数: wins, lose。

文章分类

java (7)
hadoop (17)
spark (14)
azkaban (1)
kafka (6)
python (3)
storm (4)
flume (3)
redis (2)
canal (1)
hbase (3)
es (1)
scala (0)
架构 (1)
zookeeper (1)
运维 (4)
sql (2)
算法 (6)
推荐算法 (31)
c++ (2)

文章存档

2017年09月 (10)
2017年08月 (10)
2017年07月 (1)
2017年06月 (4)

每个臂都维护一个beta分布的参数。每次试验后，选中一个臂，摇一下，有收益则该臂的wins增加1，否则该臂的lose增加1。

初始化beta参数 胜率和败率都为0.5

```
[python]

<span style="font-size: 22.5px;">  </span><span style="font-weight: normal;"><span style="font-size:14px;">prior_a = 1. # aka successes
   prior_b = 1. # aka failures
   estimated_beta_params = np.zeros((K,2))
   estimated_beta_params[:,0] += prior_a # allocating the initial conditions
   estimated_beta_params[:,1] += prior_b</span></span>
```

beta参数要在后面的计算中不断更新的。

Beta分布：

对于硬币或者骰子这样的简单实验，我们事先能很准确地掌握系统成功的概率
是未知的。为了测试系统的成功概率p，我们做n次试验，统计成功的次数k，于是很直观地就可以计算出p=k/n。然而由于系统成功的概率是未知的，这个公式计算出的p只是系统成功概率的最佳估计。也就是说实际上p也可能为其它的值，只是为其它的值的概率较小。

例如有某种特殊的硬币，我们事先完全无法确定它出现正面的概率。然后抛10次硬币，出现5次正面，于是我们认为硬币出现正面的概率最可能是0.5。但是即使硬币出现正面的概率为0.4，也会出现抛10次出现5次正面的情况。因此我们并不能完全确定硬币出现正面的概率就是0.5，所以p也是一个随机变量，它符合Beta分布。

Beta分布是一个连续分布，由于它描述概率p的分布，因此其取值范围为0到1。
Beta分布有α和β两个参数，其中α为成功次数加1，β为失败次数加1。

连续分布用概率密度函数描述，下面绘制实验10次，成功4次和5次时，系统成功概率p的分布情况。可以看出k=5时，曲线的峰值在p=0.5处，而k=4时，曲线的峰值在p=0.4处。

```
[python]
```

关闭

2017年04月 (17)

展开

阅读排行

Java中使用Jedis操作Re (8544)
spark操作parquet文件 (4623)
在HDFS上配置Alluxio (3481)
大数据去重 (2511)
SparkSQL相关语句总结 (2306)
Zookeeper可视化工具。 (1773)
TF-IDF与余弦相似性的应 (1545)
HDFS数据迁移解决方案 (1521)
mapreduce合并小文件C (1403)
Presto实现原理和美团的 (1398)

评论排行

在HDFS上配置Alluxio (1)
spark操作parquet文件 (0)
spark性能调优 (0)
python数据类型转换 (0)
python版hadoop和spark (0)
hbase shell入门 (0)
kafka入门 (0)
azkaban调度系统架构 (0)
java加载第三方jar并实例 (0)
Linux学习--gdb调试 (0)

```
n = 10
k = 5
p = np.linspace(0, 1, 100)
pbeta = stats.beta.pdf(p, k+1, n-k+1)
plot(p, pbeta, label="k=5", lw=2)

k = 4
pbeta = stats.beta.pdf(p, k+1, n-k+1)
plot(p, pbeta, label="k=4", lw=2)
xlabel("$p$")
legend(loc="best");
```

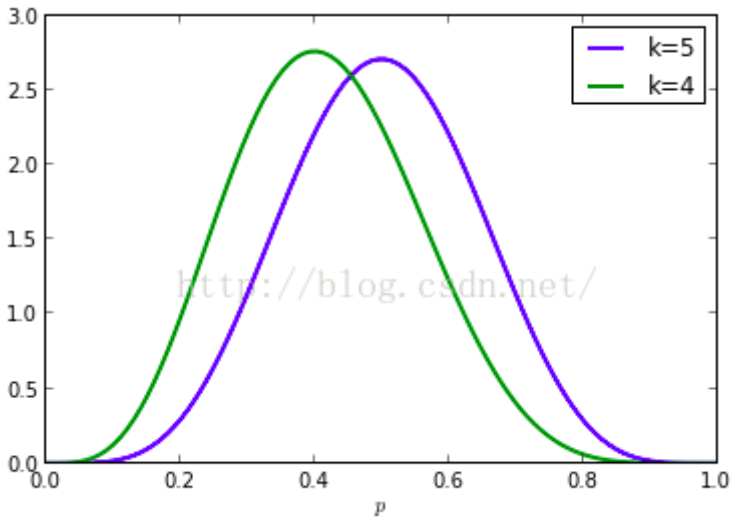

几个bandit算法：

我们先从最简单的开始，先试几次，每个臂都有了均值之后，一直选均值最大那个臂。这个算法是我们人类在实际中最常采用的，不可否认，它还是比随机乱猜要好。

[python]

```
<span style="font-size:14px;font-weight: normal;">def naive(estimated_beta_params,number_to_explore=100):
  totals = estimated_beta_params.sum(1) # totals
  if np.any(totals < number_to_explore): # if have been explored less than specified
     least_explored = np.argmin(totals) # return the one least explored
     return least_explored
  else: # return the best mean forever
     successes = estimated_beta_params[:,0] # successes
     estimated_means = successes/totals # the current means
     best_mean = np.argmax(estimated_means) # the best mean
     return best_mean</span>
```

下一个，Thompson sampling算法：

简单介绍一下它的原理：

每次选择臂的方式是：用每个臂现有的beta分布产生一个随机数b，选择所有臂产生的随机数中最大的那个臂去摇。

以上就是Thompson采样，用python实现就一行：

```
[python]

np.argmax(pymc.rbeta(1 + successes, 1 + totals - successes))
```

第三个是UCB算法：
UCB算法全称是Upper Confidence Bound(置信区间上界)，算法的具体步骤如下：

先对每一个臂都试一遍

之后，每次选择以下值最大的那个臂

其中加号前面是这个臂到目前的收益均值，后面的叫做bonus，本质上是均值的标准差，置信区间可以简单地理解为不确定性的程度，区间越宽，越不确定，反之亦反之。t是目前的试验次数，Tjt是这个臂被试次数。

这个公式反映：均值越大，标准差越小，被选中的概率会越来越大，起到了explo用；同时哪些被选次数较少的臂也会得到试验机会，起到了explore的作用。

每个item的回报均值都有个置信区间，随着试验次数增加，置信区间会变窄（逐渐确定了到底回报丰厚还是可怜）。

每次选择前，都根据已经试验的结果重新估计每个item的均值及置信区间。

选择置信区间上限最大的那个item。

“选择置信区间上界最大的那个item”这句话反映了几个意思：

1. 如果item置信区间很宽（被选次数很少，还不确定），那么它会倾向于被多次选择，这个是算法冒风险的部分；
2. 如果item置信区间很窄（备选次数很多，比较确定其好坏了），那么均值大的倾向于被多次选择，这个是算法保守稳妥的部分；

关闭

3. UCB是一种乐观的算法，选择置信区间上界排序，如果时悲观保守的做法，是选择置信区间下界排序。

```
[python]

<span style="font-size:14px;font-weight: normal;">def UCB(estimated_beta_params):
    t = float(estimated_beta_params.sum()) # total number of rounds
    totals = estimated_beta_params.sum(1)  #The number of experiments per arm
    successes = estimated_beta_params[:,0]
    estimated_means = successes/totals # earnings mean
    estimated_variances = estimated_means - estimated_means**2
    UCB = estimated_means + np.sqrt( np.minimum( estimated_variances + np.sqrt(2*np.log(t)/totals), 0.25 ) * np.log(t)
    return np.argmax(UCB)</span>
```

第四个，Epsilon-Greedy算法：
选一个(0,1)之间较小的数epsilon

每次以概率epsilon（产生一个[0,1]之间的随机数，比epsilon小）做一件事：所有臂中随机选一个。否则，选择截止当前，平均收益最大的那个臂。

是不是简单粗暴？epsilon的值可以控制对Exploit和Explore的[illegible]守，只想花钱不想挣钱。

代码：

```
[python]

<span style="font-size:14px;font-weight: normal;">from arm import Arm
import random
import numpy as np


def mean(values):
```

关闭

```
    return sum(values)*1.0/len(values)

class EpsilonGreedyAlgorithm(object):

    def __init__(self, arms, epsilon):
        self.epsilon = epsilon
        self.arms = arms
        self.values = [[] for i in arms]

    def select_arm(self):
        if random.random() > self.epsilon:
            arm_idx = self.get_best_arm_idx()
        else:
            arm_idx = self.get_random_arm_idx()

        arm = self.arms[arm_idx]
        reward = arm.pull()
        self.update(arm_idx, reward)

    def update(self, arm_idx, reward):
        self.values[arm_idx].append(reward)

    def get_best_arm_idx(self):
        max_yhat = 0.0
        max_idx = None
        for i, values in enumerate(self.values):
            yhat = 0.0 if len(values) == 0 else mean(values)
            if yhat > max_yhat:
                max_yhat = yhat
                max_idx = i

        if max_idx is None:
            return self.get_random_arm_idx()
        else:
            return max_idx

    def get_random_arm_idx(self):
        return random.randrange(len(self.arms))

```

关闭

```
46.
47.  if __name__=="__main__":
48.      epsilon = 0.1
49.      ps = [random.random() for i in range(random.randrange(2, 8))]
50.          arms = [Arm(p) for p in ps]
51.          algo = EpsilonGreedyAlgorithm(arms, epsilon=epsilon)
52.          for i in range(100):
53.              algo.select_arm()
54.          total_reward = 0
55.          for i, vals in enumerate(algo.values):
56.              total_reward += sum(vals)
57.      print "reward:", total_reward, "\t epsilon:", epsilon</span>
```


上一篇 逻辑回归

下一篇 FM模型

相关文章推荐

- 推荐系统的EE问题及Bandit算法
- Presto的服务治理与架构在京东的实践与应用--王…
- Bandit算法与推荐系统
- bandit算法原理及Python实现
- Retrofit 从入门封装到源码解析
- bandit算法原理及Python实现

- 深入掌握Kubernetes应用实践--王渊命
- bandit算法原理及Python实现
- Python基础知识汇总
- 【总结】推荐算法之工具包
- Android核心技术详解
- 自然语言处理工具Word2Vec
- Bandit算法与推荐系统
- Bandit算法与推荐系统
- 基于物品的协同过滤算法itemCF原理及python代码...
- FDA算法原理和python实现

查看评论

暂无评论

您还没有登录,请[登录]或[注册]

* 以上用户言论只代表其个人观点，不代表CSDN网站的观点或立场